INTERNAL AI ASSISTANT

Bank Operations Copilot

Group 21:
Dương Trịnh Hoài An - 2A202600050
Nguyễn Mạnh Quyền - 2A202600481
Nguyễn Tiến Đạt - 2A202600217
Trần Ngọc Hùng - 2A202600429
Bùi Đức Thắng - 2A202600002

01 Tổng Quan Dự Án

TÊN DỰ ÁN

Bank Operations Copilot

NGƯỜI DÙNG

Giao dịch viên · Back-office · Compliance

BÀI TOÁN

Tra cứu policy, KYC, SOP tín dụng & biểu mẫu nhanh, đúng quy trình

GIÁ TRỊ MANG LẠI

1. Giảm thời gian tra cứu thủ công
2. Giảm nguy cơ nhầm tài liệu hoặc sai bước xử lý
3. Hỗ trợ chuẩn hóa vận hành nội bộ

02 Enterprise Context & Ràng Buộc

NHÓM DỮ LIỆU HỆ THỐNG

- Policy & quy định nội bộ
- Tài liệu compliance
- Tài liệu KYC / AML
- Thông tin hồ sơ khách hàng
- SOP tín dụng & xử lý hồ sơ
- Metadata truy vấn, log & audit trail
- Biểu mẫu nghiệp vụ & checklist

⚠ **Mức độ nhạy cảm dữ liệu: RẤT CAO — Ngân hàng thương mại nội bộ**

3 RÀNG BUỘC LỚN NHẤT

01 Bảo mật & kiểm soát dữ liệu

Dữ liệu mức độ nhạy cảm rất cao, yêu cầu kiểm soát chặt chẽ

02 Audit trail & khả năng truy vết

Toàn bộ truy vấn cần được ghi nhận đầy đủ để tuân thủ compliance

03 Tích hợp hệ thống cũ

Kết nối với workflow phê duyệt và core banking hiện có

03 Kiến Trúc Triển Khai Đề Xuất

HYBRID MODEL

ON-PREM / PRIVATE

- Hồ sơ khách hàng
- SOP tín dụng nội bộ
- KYC & AML documents
- IAM / phân quyền
- Tài liệu compliance
- Audit trail & log

→ Controlled Data Flow

CLOUD

- Lớp ứng dụng
- Semantic caching
- AI service (controlled)
- Truy vết nguồn answer
- Monitoring & alerts
- Cost optimization

04 Cost Anatomy

300	13.2M	~$950
req/ngày	tokens/tháng	USD/tháng
MVP Usage	**Token Volume**	**Tổng chi phí TB**

PHÂN BỔ CHI PHÍ MVP / THÁNG

Human Review	$250–400	38%
Maintenance / Ops	$300–500	40%
Backend + DB + Vector + Cache	$120–180	14%
Logging + Monitoring + Audit	$50–80	6%
LLM / API	$30–50	4%

TỔNG MVP: $750–1,200 USD/tháng | Mức tham chiếu: ~$950/tháng

05 Cost Optimization

01

Semantic Caching

MỤC TIÊU

Giảm request lặp phải gọi model

TIẾT KIỆM

LLM/API · Compute · Latency

TRADE-OFF

Quản lý invalidation khi tài liệu thay đổi

Ngay từ MVP

02

Prompt Compression

MỤC TIÊU

Giảm token đầu vào không cần thiết

TIẾT KIỆM

Input tokens · Chi phí API

TRADE-OFF

Nén quá mạnh có thể giảm chất lượng

Ngay từ MVP

03

Selective Inference

MỤC TIÊU

Phân tầng request theo độ phức tạp

TIẾT KIỆM

Model đắt tiền · Human review không cần thiết

TRADE-OFF

Cần routing logic rõ ràng

Triển khai sớm ở mức cơ bản

06 Reliability & Scaling

3 TÌNH HUỐNG CHÍNH

- Traffic tăng đột biến
- Provider timeout / lỗi
- Response chậm

PHẢN ỨNG NGẮN HẠN

- · Rate limiting
- · Circuit breaker
- · Queue cho non-urgent
- · Fallback → cache / retrieval-only
- · Retry có giới hạn

GIẢI PHÁP DÀI HẠN

→ Autoscaling

→ Tối ưu retrieval & prompt

→ Semantic caching

→ Selective inference

→ Multi-provider / model dự phòng

→ Capacity planning & outage testing

KEY METRICS TO MONITOR

- Success rate · Timeout rate
- p95/p99 Latency
- Cache hit rate · Failover rate
- Human escalation rate

Q & A